D02 · Planning Maturity & Digital Transformation

04 · IA / ML en planeación — qué funciona y qué no

Arquitectura de Referencia de la Cadena de Suministro v2.2 · mrsupplychain.ai

1 QUÉ ES

Una práctica disciplinada de IA/ML en planeación no pregunta "¿debemos usar ML?" sino "¿dónde ML le gana al baseline?" — seleccionando técnicas por dónde superan demostrablemente a los métodos estadísticos establecidos, comparando cada modelo contra un baseline simple, y desplegando solo donde el lift es real y los datos lo soportan, en vez de aplicar ML por hype a problemas que un método más simple ya resuelve mejor.

2 POR QUÉ IMPORTA

Makridakis, Spiliotis & Assimakopoulos 2018 **(Makridakis et al., 2018 — peer-reviewed)**, comparando métodos de pronóstico de machine learning y estadísticos, encontró que los métodos de ML no superaban sistemáticamente a otros mucho más simples y a menudo eran vencidos por ellos — mientras costaban mucho más en cómputo y complejidad. El resultado no es anti-ML; es que la técnica debe emparejarse al problema, y la complejidad no es un proxy de precisión. Las organizaciones de planeación ignoran esto de rutina, aplicando ML de caja negra a series suaves que un modelo simple pronostica mejor, o lanzando ML sobre datos que no pueden soportarlo. Los pilotos fallan en vencer al baseline contra el que nunca se midieron, y cada fracaso erosiona la confianza del liderazgo — de modo que **las oportunidades genuinas de ML, donde el lift es real, quedan hambreadas de credibilidad por las impulsadas por hype que nunca debieron lanzarse**.

3 CÓMO SE HACE

1. **Empieza por el problema, no la técnica.** Define el problema de planeación y pregunta qué método le ajusta, en vez de empezar con "queremos usar ML". Los proyectos técnica-primero buscan un problema que justifique la herramienta; los proyectos problema-primero encuentran el método — a veces ML, a menudo no — que de verdad gana.
2. **Compara cada modelo contra un baseline simple.** El pronóstico estacional ingenuo y un modelo estadístico estándar son la vara. Un modelo de ML que no les gana fuera de muestra ha fallado sin importar su sofisticación, y desplegarlo de todos modos es pagar más por menos.
3. **Apunta el ML donde tiene una ventaja estructural.** El ML gana su complejidad en problemas con muchos drivers que interactúan, no-linealidades, señales externas ricas o patrones de alta dimensión — demand sensing, promociones complejas, inputs de imagen/texto. Rara vez le gana a un buen modelo estadístico en una serie univariada limpia y suave. Empareja el método a la forma del problema.
4. **Verifica que los datos puedan soportar el modelo.** El ML es más hambriento de datos y más sensible a la calidad de datos que los métodos estadísticos. Sobre datos fragmentados o escasos, un modelo complejo sobreajusta y rinde peor. Confirma que el cimiento de datos integrado existe antes de lanzar el modelo que depende de él.
5. **Mantén el modelo lo bastante interpretable para confiar y gobernar.** Un pronóstico de caja negra que los planeadores no pueden interrogar será anulado o ignorado, destruyendo su valor. Favorece modelos cuyos drivers puedan explicarse, y mide el valor agregado del pronóstico para que la contribución del modelo sea visible y rendible.
6. **Industrializa solo lo que sobrevive el benchmark.** Mueve un modelo de piloto a producción solo después de que le gane al baseline en datos fuera de muestra con un pipeline mantenible. Escalar un modelo que nunca pasó la vara institucionaliza el costo y la desconfianza; escalar uno probado es donde el valor real se compone.

EJEMPLO TRABAJADO — ILUSTRATIVO

Una empresa lanzó una iniciativa de pronóstico con deep learning a través de todo el catálogo — **base: nunca comparada contra el pronóstico estadístico existente, vencida por él en los A-items suaves, piloto de ML declarado un fracaso, confianza del liderazgo en analítica dañada**. Reinició problema-primero: mantuvo métodos estadísticos para series suaves, apuntó el ML solo a demand sensing y promociones complejas donde tenía ventaja, comparó todo contra los baselines ingenuo y estadístico. Resultados: **ML desplegado en el ~20% de los problemas donde de verdad le ganó al baseline, lift de precisión medible ahí, y credibilidad de analítica reconstruida** — porque la técnica por fin se emparejó al problema.

EN LA PRÁCTICA

Compara contra baseline cada modelo

Haz de vencer al baseline ingenuo y estadístico fuera de muestra una compuerta obligatoria antes de que cualquier modelo avance. El benchmark es la única disciplina que evita que la complejidad se disfrace de valor; ningún modelo se gana el despliegue sin pasarla.

Empareja la técnica a la forma del problema

Reserva el ML para problemas con la estructura que lo premia y mantén los métodos estadísticos donde ganan. Un portafolio que usa el método correcto por problema supera a uno que aplica una sola técnica de moda en todos lados — y cuesta menos correr y mantener.

Mide el valor agregado del pronóstico en cada modelo

Rastrea si cada modelo — y cada override humano de él — agrega o destruye precisión versus el baseline. El FVA hace visible la contribución real del modelo y convierte "usamos IA" en "la IA agrega X puntos de precisión aquí", que es la única afirmación que vale la pena hacer.

Secuencia el ML después de la madurez de datos y proceso

Despliega ML solo una vez que la capa de datos integrada y el proceso sólido existen debajo. El ML sobre datos fragmentados y un proceso roto amplifica la disfunción y falla el benchmark; la secuencia de madurez — proceso, datos, luego analítica avanzada — es lo que le da al ML el cimiento que necesita para de verdad ganar.

QUÉ SE USA

IA / ML EN PLANEACIÓN

o9 / SAP IBP / Kinaxis — ML embebido en planeación — Plataformas de planeación con ML embebido para demand sensing, pronóstico y detección de patrones, gobernado dentro del workflow de planeación y comparado contra baselines estadísticos. **(o9, SAP, Kinaxis — vendor)** La opción cuando el ML debe vivir dentro del plan con disciplina de FVA y benchmark incorporada.

Blue Yonder / RELEX — ML aplicado para retail/CPG — ML aplicado sólido para demand sensing, promociones y reabasto donde la estructura del problema lo premia. **(Blue Yonder, RELEX — vendor)** Un buen ajuste donde el ML apunta a los problemas de muchos drivers — promociones, sensing a nivel tienda — que de verdad mejora.

Plataformas de ciencia de datos (Databricks, ML open-source) — Plataformas generales de ML y ciencia de datos para modelos a la medida donde el ML de planeación empaquetado se queda corto. **(Databricks, frameworks open-source — vendor)** La opción vertical cuando el problema de ML es a la medida y el equipo tiene la capacidad de construirlo y gobernarlo rigurosamente.

Para operaciones que aún no necesitan ML — Métodos estadísticos bien elegidos (Python statsforecast, R fable) comparados rigurosamente — que le ganan al ML mal aplicado en la mayoría de los problemas de planeación. La respuesta honesta para muchas organizaciones es que el baseline es la herramienta correcta; el ML es el siguiente paso solo donde un piloto comparado prueba que gana.

4 EN CORTO

Las operaciones que comparan el ML contra un baseline simple y lo despliegan solo donde gana capturan lift real y protegen su credibilidad de analítica; las que aplican ML por hype lanzan pilotos que pierden contra un pronóstico ingenuo y queman la confianza que las oportunidades genuinas necesitaban. El error de IA más caro en planeación no es sub-invertir — es desplegar complejidad donde un método simple ya gana, y luego confundir el fracaso con prueba de que la IA no funciona. Empareja la técnica al problema, mide contra el baseline, y deja que el lift, no el hype, decida.

De la arquitectura de referencia SCRA v2.2 · mrsupplychain.ai · © 2026 Ismael López · Mr. Supply Chain® México