D03 · Automatización Industrial y Robótica

03 · Sistemas de visión e inspección por máquina

Arquitectura de Referencia de la Cadena de Suministro v2.2 · mrsupplychain.ai

1 QUÉ ES

Los sistemas de visión son hardware de imagen montado en máquina (cámaras, iluminación, ópticas) emparejado con software (adquisición de imagen, procesamiento, lógica de decisión) que automatiza tareas de inspección, medición, identificación y guía. El despliegue va desde compuertas de calidad al final de línea (presencia/ausencia, verificación dimensional, detección de defectos) hasta control en proceso (retroalimentación al equipo que previene la formación del defecto). La diferencia económica entre los dos despliegues es enorme; la diferencia técnica es a dónde van los datos después de que la imagen se procesa.

2 POR QUÉ IMPORTA

Los sistemas de visión son una de las inversiones de automatización con el ROI más alto disponible para la manufactura moderna — y una de las más consistentemente sub-desplegadas porque el caso de uso dominante es inspección al final de línea en lugar de control en proceso. **La asimetría es enorme: un sistema de visión desplegado como inspector al final de línea detecta el defecto y cuenta el scrap; el mismo sistema de visión desplegado en proceso con retroalimentación al equipo previene la formación del defecto en primer lugar**. El texto fundacional sobre aplicaciones de machine vision cuantifica el envelope técnico **(Steger, Ulrich & Wiedemann, 2018 — peer-reviewed, "Machine Vision Algorithms and Applications", 2da ed., Wiley-VCH)**, y los datos de industria sobre sistemas desplegados son consistentes: **los despliegues de visión al final de línea típicamente pagan capex en 18 a 30 meses a través de reducción de scrap y evitar mano de obra; los despliegues de control en proceso con retroalimentación al equipo típicamente pagan en 6 a 12 meses a través de prevención de defectos**. La brecha de ROI de 2 a 3x es estructural — la misma cámara, el mismo algoritmo, el mismo operador, pero valor radicalmente distinto dependiendo de si el sistema controla o meramente cuenta.

3 CÓMO SE HACE

1. **Especifica la tarea de inspección antes de considerar cualquier cámara — y fuerza la pregunta de si la inspección debe ser en proceso o al final de línea.** Un defecto detectado al final de línea es una parte ya producida mal; un defecto detectado en proceso puede prevenirse. La pregunta de diseño del caso es si el equipo aguas arriba puede ser controlado por la señal de visión (cerrar el loop) o solo auditado por ella (loop abierto). Las plantas que por default van a end-of-line porque es más fácil de desplegar capturan aproximadamente la mitad del valor disponible.
2. **Ingenia iluminación antes que óptica, óptica antes que cámara, cámara antes que software — en ese orden.** La mayoría de las fallas de sistema de visión son fallas de iluminación disfrazadas de fallas de algoritmo. La calidad de imagen que la cámara captura depende de la iluminación (dirección, intensidad, longitud de onda, polarización), la óptica (longitud focal del lente, profundidad de campo, distancia de trabajo) y la cámara (resolución, tipo de sensor, modo de obturador). Un sistema de visión que requiere un algoritmo sofisticado para compensar mala iluminación es un sistema de visión que va a fallar cuando las condiciones cambien.
3. **Elige entre algoritmos basados en reglas y deep learning por la signatura del modo de falla — no por cuál tecnología suena más moderna.** La visión basada en reglas (Cognex VisionPro clásica, MVTec HALCON) es la elección correcta para inspecciones bien definidas con características geométricas o fotométricas claras (verificación dimensional, presencia/ausencia, reconocimiento de caracteres). La visión por deep learning (Cognex ViDi, Landing AI, Neurala) es la elección correcta para defectos variables, naturalmente ocurrentes, con alta variabilidad visual (defectos de superficie, materiales orgánicos, inspección compleja de ensamble). Las plantas que fuerzan deep learning en problemas basados en reglas desperdician cómputo y datos de entrenamiento; las plantas que fuerzan basado en reglas en problemas de deep learning chocan con un techo del 80 al 85% de detección.
4. **Cierra el loop de control donde el caso lo permita — alimenta el output de visión de regreso al equipo que causó el defecto.** Un sistema de visión midiendo calidad de impresión al final de una línea de impresión te dice que la impresión está mala; un sistema de visión midiendo calidad de impresión entre impresión y curado que ajusta el flujo de tinta o la temperatura en tiempo real previene la impresión mala. Cerrar el loop requiere (a) un parámetro de equipo controlable, (b) una signatura de defecto predictiva de la deriva del parámetro, (c) integración entre el controlador de visión y el PLC del

equipo. Cuando los tres existen, el despliegue en proceso es correcto; cuando falta alguno, el despliegue end-of-line es la opción realista.

5. **Corre un MSA (análisis de sistema de medición) sobre el sistema de visión como si fuera una galga — porque lo es.** Los sistemas de visión derivan como cualquier sistema de medición: contaminación del lente, degradación de iluminación, deriva del modelo de software en sistemas de deep learning, cambio de temperatura ambiental. La disciplina de MSA (gauge R&R, estudio de linealidad, estudio de sesgo) aplica tanto a la visión como a los micrómetros. Las plantas que se saltan MSA en sistemas de visión corren en fe de que la cámara está bien; las plantas que incluyen la visión en su programa MSA atrapan la deriva antes de que se vuelva escape de calidad.
6. **Planea para la economía de falsos rechazos, no solo para la economía de defectos perdidos.** Un sistema de visión que rechaza el 0.3% de partes buenas como defectuosas en una línea de alto volumen genera una corriente significativa de scrap propio. La tasa aceptable de falso rechazo depende del costo de la parte, la consecuencia de la inspección y la capacidad aguas abajo de triagiar rechazos. Las plantas que optimizan solo la tasa de pérdida producen sistemas de visión que atrapan cada defecto y desechan partes sanas; las plantas que optimizan el punto operativo conjunto de tasa-de-pérdida / tasa-de-falso-rechazo producen sistemas que pagan económicamente.

EJEMPLO TRABAJADO — ILUSTRATIVO

Un contract manufacturer de electrónicos ensambla PCBs de montaje superficial a través de 6 líneas, con AOI (inspección óptica automatizada) end-of-line detectando **tasa de defecto del 8.2% ($6.1M costo anual de retrabajo; 14 operadores dedicados a celdas de retrabajo)**. Los defectos son dominados por tres signaturas: puentes de soldadura (47% de defectos), desalineación de componente (28%) y tombstones post-reflow (16%). El análisis de causa raíz muestra que las tres signaturas se originan en operaciones específicas aguas arriba: puentes de soldadura en la deposición de pasta, desalineación en la colocación de componente, tombstones en el perfil de reflow. La implementación: **migrar de AOI end-of-line a 3 estaciones de visión en proceso** con retroalimentación de loop cerrado — (1) la visión de deposición de pasta alimenta altura/volumen de regreso al controlador de presión del dispensador, (2) la visión de colocación verifica la orientación del componente y dispara rechazo antes del reflow, (3) la visión térmica post-reflow alimenta de regreso al controlador del perfil del horno de reflow. AOI end-of-line se retiene pero como auditoría, no como compuerta. Resultados a 12 meses: **tasa de defecto end-of-line 8.2% -> 1.4% (-83%), costo de retrabajo $6.1M -> $1.5M (-75%), 14 operadores de retrabajo redesplegados a estaciones de valor agregado, payback del sistema de visión 9 meses sobre una inversión total de $740K**. Los mismos defectos que previamente se detectaban y retrabajaban ahora se previenen en su formación; la cámara AOI que ya existía contribuyó casi nada a ese resultado porque estaba mirando después del hecho.

EN LA PRÁCTICA

Especifica en-proceso o fin-de-línea antes de considerar hardware

La visión de fin-de-línea es un sistema de medición aplicado a producto terminado; la visión en-proceso con retroalimentación es un sistema de control aplicado al proceso productivo. Mismo hardware, despliegues categóricamente diferentes — y diferencia de ROI 2–3×.

Diseña iluminación antes que óptica, antes que cámara, antes que software

La mayoría de los despliegues de visión fallidos fallan en iluminación **(Steger, Ulrich & Wiedemann, 2018 — peer-reviewed, Wiley-VCH)**. La cámara con mala iluminación no resuelve nada que el algoritmo de deep-learning pueda recuperar; la cámara con buena iluminación muchas veces hace innecesario al algoritmo. Iluminación primero.

Elige reglas vs deep-learning por la firma del modo de falla

Los defectos determinísticos (presencia/ausencia, dimensional, color) pertenecen a la visión basada en reglas; los defectos superficiales variables, la inspección de material orgánico y las firmas-que-resisten-especificación pertenecen al deep-learning. La elección equivocada cuesta 5× el esfuerzo de ingeniería por la mitad del desempeño.

Planea para la economía de falsos rechazos, no solo para la de defectos perdidos

Una tasa de detección de defectos del 99.5% suena excelente hasta que la tasa de falsos rechazos es 3% en una línea de alto volumen — punto en el cual el sistema rechaza más producto bueno que malo. El MSA sobre visión es la disciplina gauge R&R que hace visible esto; sin esto, el sistema pasa el demo y falla en producción.

QUÉ SE USA

PLATAFORMAS DE VISIÓN POR MÁQUINA

Cognex (In-Sight, VisionPro, ViDi) — La plataforma dominante de machine vision empresarial con base instalada robusta en automotriz, electrónicos, empaque y ciencias de la vida; ecosistema integrado de hardware y software con capacidad tanto basada en reglas como de deep learning **(Cognex — vendor)**.

Keyence (serie CV-X, IV3, XG-X) / Omron (serie FH) — Alternativas empresariales robustas a Cognex con capacidad técnica competitiva y variación de preferencia regional; particularmente fuertes en mercados Asia-Pacífico y en operaciones con huella existente de sensores Keyence u Omron **(Keyence — vendor; Omron — vendor)**.

Landing AI / Neurala / MVTec HALCON — Plataformas de visión especializadas en deep learning para casos donde la visión basada en reglas no puede alcanzar la precisión requerida — detección de defectos de superficie, inspección de material biológico/orgánico, verificación compleja de ensamble **(Landing AI — vendor; MVTec — vendor)**.

OpenCV + Python + una cámara industrial + ingeniero de visión in-house — Para operaciones con capacidad de ingeniería de visión — librerías open-source (OpenCV, scikit-image, PyTorch) sobre cámaras industriales estándar (Basler, FLIR, Allied Vision). El TCO más bajo y la flexibilidad más alta; requiere que la capacidad de ingeniería in-house sea real y continua.

4 EN CORTO

El sistema de visión que cuenta defectos al final de línea es una cámara cara que cuantifica scrap — la visión sin un loop de control al proceso no previene nada. Especifica si la inspección debe ser en proceso o al final de línea antes de considerar hardware, ingenia iluminación antes que óptica antes que cámara antes que software, elige basado en reglas vs deep learning por la signatura del modo de falla, cierra el loop de control donde sea que el caso lo permita, corre MSA sobre sistemas de visión como lo harías sobre cualquier galga, y planea para la economía de falsos rechazos no solo para la economía de defectos perdidos. La brecha de ROI de 2 a 3x entre control en proceso e inspección end-of-line es estructural — y vive enteramente en si el despliegue fue diseñado como control o meramente como medición.

De la arquitectura de referencia SCRA v2.2 · mrsupplychain.ai · © 2026 Ismael López · Mr. Supply Chain® México